## **HW3** Report

111065541 張騰午

## **Implement**

### Hw3-1

做 Floyd-Warshal,時間複雜度  $O(n^3)$ ,不過在 i,j 兩個迴圈增加 omp 指令來平行化。

另外在 initial 部分使用 fill 一次性填入 INF 並用 omp 指令來增加速度

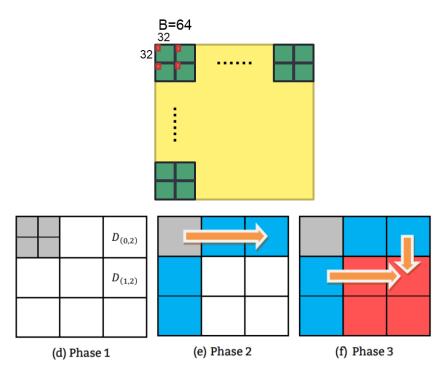
```
#pragma omp parallel for schedule(guided, 1)
for (int i = 0; i < vertex; ++i) {
    fill(Dist[i].begin(), Dist[i].end(), INF);
    Dist[i][i] = 0;
}</pre>
```

### Hw3-2

使用了助教提供範例 blocked-Floyd-Warshall 演算法,input 時修改使用 int \*fpt = (int\*)mmap(NULL, 2\*sizeof(int), PROT\_READ, MAP\_PRIVATE, file, 0);如此直接將所有資料一次性讀取,之後再寫入 V\*V 的 Dist 中,如此可以減少 I/O 時間。

而演算法計算方面思路如下:

blocking factor 64,而一個 GPU 的 block 為 32 threads\*32 threads,因此整個演算 法把矩陣分成數個 64\*64 block,每個 block 使用一個 GPU 32\*32 的 block 下去算 要計算 4 次,一個 thread 在一個 B\*B block 要算 4 個點,如下圖紅色標示處,4 個點距離左右、上下皆為 32,



三個 Phase 分別用一個 32\*32 block\_dim threads、兩行 ceil(V/B)個 32\*32 block\_dim threads 以及 ceil(V/B)\*ceil(V/B)個 32\*32 block\_dim threads 平面進行計算,宣告方式如下:

```
int blocks = ceil(V, B);
dim3 block_dim(BLOCK_SIZE, BLOCK_SIZE);//BLOCK_SIZE=32
dim3 grid_dim(blocks, blocks);
dim3 grid_dim2(blocks, 2);

for (int r = 0; r < round; ++r) {
    // phase 1
    Phase1<<<<1, block_dim>>>(dst, r, V);
    // phase 2
    Phase2_<<<<gri>grid_dim2, block_dim>>>(dst, r, V);
    // phase 3
    Phase3<<<<grid_dim, block_dim>>>(dst, r, V);
    //Phase3_<<<<grid_dim, block_dim>>>(dst, r, V);
    //Phase3_<<<<grid_dim, block_dim>>>(dst, r, V);
```

Phase 中需要計算的點座標如下(用一維方式表示),

## Phase 1(僅 pivot block)

```
__global___ void Phase1(int *dst, int Round, int V){
    int i = threadIdx.y;
    int j = threadIdx.x;
    int i B = i + BLOCK_SIZE;
    int j B = j + BLOCK_SIZE;
    int j B = j + BLOCK_SIZE;
    //B為64 · 一次處理一個64*64 · 但block dim僅為32*32 · 因此一個大block分成四個小block · 一個thread要計算四個小block四個點
    // 1 2
    // 3 4
    int offset = Round * B * (V+1);
    int blk_pt1 = offset + i * V + j;
    int blk_pt2 = offset + i * V + j_B;
    int blk_pt3 = offset + i_B * V + j;
    int blk_pt4 = offset + i_B * V + j_B;
    int blk_pt4 = offset + i_B * V + j_B;
```

Phase 2(下左,依據 blockld.y 的值判斷計算 pivot row 的 block 或是 pivot column 的 block)

Phase 3(下右,使用同 row 還有同 column 的 pivot row/column block 來計算值)

```
int blk_pt1 = offset + i * V+ j;
int blk_pt2 = offset + i * V + j_B;
int blk_pt3 = offset + i_B * V + j;
                                                                int offset_ = blockIdx.y * B * V + blockIdx.x * B;
int blk_pt4 = offset + i_B *V + j_B;
                                                                int blk_pt1 = offset_ + i * V + j;
int blk_pt2 = offset_ + i * V + j_B;
//for same col block
if(blockIdx.y == 0) {
                                                               int blk_pt3 = offset_ + i_B * V + j;
int blk_pt4 = offset_ + i_B * V + j_B;
     offset_rc = blockIdx.x * B * V + Round * B;
     pivot_rc_blk1 = offset_rc + i * V + j;
     pivot_rc_blk2 = offset_rc + i * V + j_B;
                                                                int offset_r = blockIdx.y * B * V + Round * B;
int row_blk1 = offset_r + i * V + j;
int row_blk2 = offset_r + i * V + j_B;
     pivot_rc_blk3 = offset_rc + i_B * V + j;
     pivot_rc_blk4 = offset_rc + i_B * V + j_B;
                                                                int row_blk3 = offset_r + i_B * V + j;
}else {//for same row block
                                                                int row_blk4 = offset_r + i_B * V + j_B;
    offset_rc = Round * B * V + blockIdx.x * B;
     pivot_rc_blk1 = offset_rc + i * V + j;
                                                                //same col
                                                                int offset_c = Round * B * V + blockIdx.x * B;
int col_blk1 = offset_c + i * V + j;
int col_blk2 = offset_c + i * V + j_B;
     pivot_rc_blk2 = offset_rc + i * V + j_B;
     pivot rc blk3 = offset rc + i B * V + j;
     pivot_rc_blk4 = offset_rc + i_B * V + j_B;
                                                                int col_blk3 = offset_c + i_B * V+ j;
                                                                int col_blk4 = offset_c + i_B * V + j_B;
```

三個 phase 結束後先在 gpu 上用 devicetodevice 的 CudaMemcpy 把本來 V\*V 存在 dst 的資料複製到另一個 vertex\*vertex 大小的 dst ,

之後 output 時就可以直接 fwrite(Dist, sizeof(int), vertex\*vertex, outfile);一次性把 vertex\*vertex 量的資料全部寫入 output file 中減少 I/O 時間。

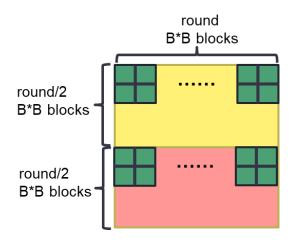
用\_\_shared\_\_ int share[B][B];創建 share memory,來讀取後續比較還有計算需要的值,每個 thread 將自己負責的值存入 share memory,並進行後續更新值的計算,存取修改 share memory 後要\_\_syncthreads();進行同步,最後把 share memory 中的值存回 dst 中。

另外在進行比較計算時,發現使用\_\_device\_\_函數再調用 cuda 內建函數 min,讓計算在 GPU 上進行會比直接用 if 判斷式更快。

```
device int min (int a, int b) {return min(a, b);}
```

#### Hw3-3

3-2 的程式大致不變,查詢相關資料並和同學討論後只在 phase 3 使用兩 GPU 平分執行,因為有了 start\_point,phase 3 計算座標時要多加入 y 軸方面 offset。平分方式如下圖,整個矩陣本來能分成 round\*round 個 B\*B block,在 y 軸上分成上下兩部份給兩個 GPU 做。



程式在執行三個 phase 時用#pragma omp parallel num\_threads(2)來執行兩 gpu,接著取得 thread\_id 以及 neighbor thread id,並計算雙方需要做的數量還有起始點,若是 round 無法被整除,則將多的一個 round 加在 thread\_id=0 的那邊

```
unsigned int thread_id = omp_get_thread_num();
cudaSetDevice(thread_id);
// neighbor
unsigned int neighbor_thread_id;
if(thread_id){
                                                  unsigned int rounds_to_do = round / 2;
    neighbor_thread_id = 0;
                                                  unsigned int rounds_to_do_neighbor = round / 2;
                                                  if (thread_id == 0) {
}else{
                                                      rounds_to_do += round % 2;
    neighbor_thread_id = 1;
                                                  }else{rounds_to_do_neighbor += round % 2;}
unsigned int start_point;
   start_point = rounds_to_do_neighbor;
   start point = 0;
```

進入迴圈後每次都得進行迴圈 r 對應的那一行 block 數據交換(pivot row),通過 #pragma omp barrier 來確保兩邊都已經完成數據操作。

```
for (int r = 0; r < round; ++r) {
    if (r >= start_point && r < (start_point + rounds_to_do)) {
        cudaMemcpy(dst[neighbor_thread_id] + r * B * V, dst[thread_id] + r * B * V, B * V * sizeof(int), cudaMemcpyDefault)
    }
    #pragma omp barrier</pre>
```

# **Experiment & Analysis**

# i · Methodology

### a. System Spec

在課程提供的hades上進行測試

+				
		Persistence-M  Pwr:Usage/Cap	Bus-Id Disp.A Memory-Usage	Volatile Uncorr. ECC   GPU-Util Compute M.
0		1080 On	000000000:4B:00.0 Off	N/A
32%		14W / 216W	2MiB / 8114MiB	0% Default
1		1080 On	00000000:4D:00.0 Off	N/A
10%		18W / 216W	11MiB / 8113MiB	0% Default

## b. Blocking Factor (hw3-2)

### **GOPS**

C21.1 進行 --metrics inst\_integer 計算再除以執行時間

### B=64

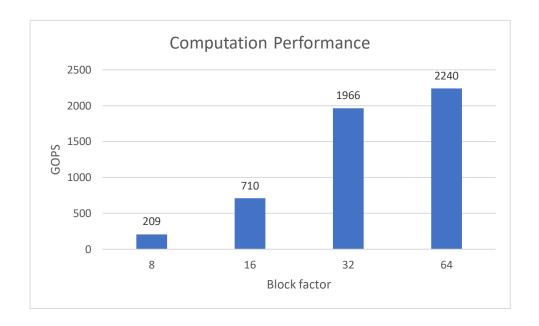
### B=32

```
| Imager Instructions | 1563894272 | 1563894272 | 1563894272 | 1563894272 | 1563894272 | 1563894272 | 1563894272 | 1563894272 | 1563894272 | 1563894272 | 1563894272 | 1563894272 | 1563894272 | 1563894272 | 1563894272 | 1563894272 | 1563894272 | 1563894272 | 1563894272 | 1563894272 | 1563894272 | 1563894272 | 1563894272 | 1563894272 | 1563894272 | 1563894272 | 1563894272 | 1563894272 | 1563894272 | 1563894272 | 1563894272 | 1563894272 | 1563894272 | 1563894272 | 1563894272 | 1563894272 | 1563894272 | 1563894272 | 1563894272 | 1563894272 | 1563894272 | 1563894272 | 1563894272 | 1563894272 | 1563894272 | 1563894272 | 1563894272 | 1563894272 | 1563894272 | 1563894272 | 1563894272 | 1563894272 | 1563894272 | 1563894272 | 1563894272 | 1563894272 | 1563894272 | 1563894272 | 1563894272 | 1563894272 | 1563894272 | 1563894272 | 1563894272 | 1563894272 | 1563894272 | 1563894272 | 1563894272 | 1563894272 | 1563894272 | 1563894272 | 1563894272 | 1563894272 | 1563894272 | 1563894272 | 1563894272 | 1563894272 | 1563894272 | 1563894272 | 1563894272 | 1563894272 | 1563894272 | 1563894272 | 1563894272 | 1563894272 | 1563894272 | 1563894272 | 1563894272 | 1563894272 | 1563894272 | 1563894272 | 1563894272 | 1563894272 | 1563894272 | 1563894272 | 1563894272 | 1563894272 | 1563894272 | 1563894272 | 1563894272 | 1563894272 | 1563894272 | 1563894272 | 1563894272 | 1563894272 | 1563894272 | 1563894272 | 1563894272 | 1563894272 | 1563894272 | 1563894272 | 1563894272 | 1563894272 | 1563894272 | 1563894272 | 1563894272 | 1563894272 | 1563894272 | 1563894272 | 1563894272 | 1563894272 | 1563894272 | 1563894272 | 1563894272 | 1563894272 | 1563894272 | 1563894272 | 1563894272 | 1563894272 | 1563894272 | 1563894272 | 1563894272 | 1563894272 | 1563894272 | 1563894272 | 1563894272 | 1563894272 | 1563894272 | 1563894272 | 1563894272 | 1563894272 | 1563894272 | 1563894272 | 1563894272 | 1563894272 | 1563894272 | 1563894272 | 1563894272 | 1563894272 | 1563894272 | 1563894272 | 1563894272 | 1563894272 | 1563894272 | 1563894272 | 1563894272 | 1563894
```

### B = 16

#### B=8

```
■ [pp23s71@hades01 hw3-2]$ srun -p prof -N1 -n1 --gres=gpu:1 nvprof ./hw3-2 /home/pp23/share/hw3-2/cases/c21.1 B8.out
==158503== Nr0filing application: ./hw3-2 /home/pp23/share/hw3-2/cases/c21.1 B8.out
==158503== Profiling application: ./hw3-2 /home/pp23/share/hw3-2/cases/c21.1 B8
```



從圖中可發現隨著 blocking factor 增加,每秒的 operation 也在增加,推測這是因為並行化程度增加,同時進行的計算操作變多的緣故。

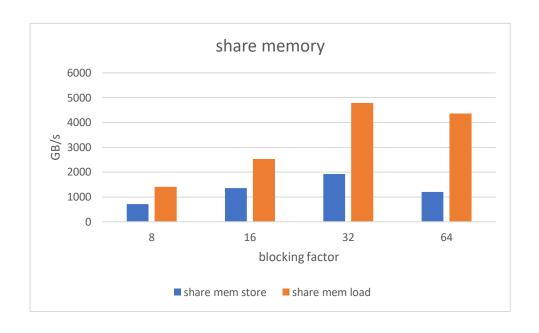
# global/shared memory bandwidth

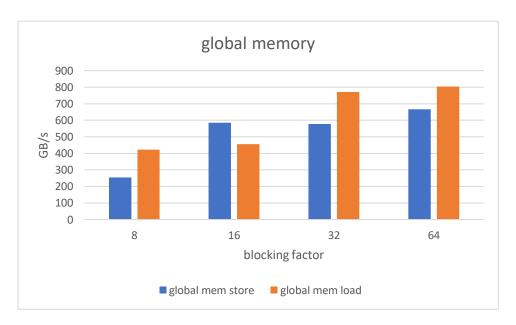
## B64\*64

B32\*32

### B16\*16

### **B8\*8**



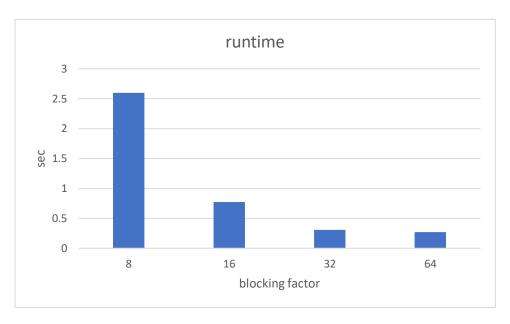


由於程式中對於 share memory 的存取計算,Share memory store 隨著 blocking factor 增加有非常明顯的差異,幅度上千,但 share memory 也有數量限制,因此不會一直上升。global 部份則沒有那麼劇烈的變化。

## c. Optimization (hw3-2)

## 1. Large blocking factor

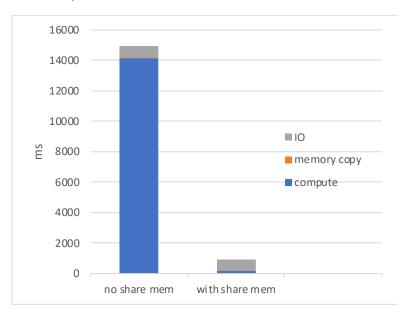
c21.1 進行測試四種 blocking factor 下的執行時間



較大的 blocking factor 的確可以明顯降低運行時間

### 2. share memory

使用 share memory 可以達到很好的優化效果,對 c21.1 比較使用 share memory 還有 no share memory,兩者差距是巨量的。



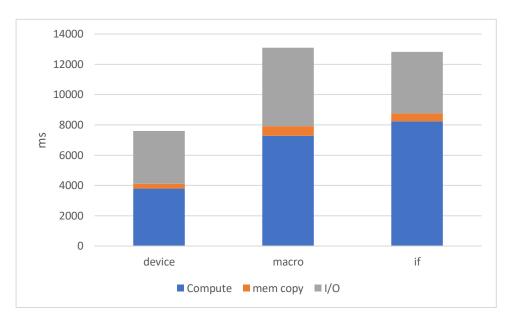
### 3. 比較計算優化

以 p16k1 V=16000 測資,在 block-floyd-warshall 計算時比較使用\_\_device\_\_函數 \_\_device\_\_ int min\_(int a, int b) {return min(a, b);}

、在 GPU 上執行再調用 cuda 內建函數 min,以及直接使用 if 還有在#define 定義一個 macro:

#define min\_\_(a, b) ((a) < (b) ? (a) : (b))

三種方式進行比較:



測量方式是使用 cudaEvent 計算每部分累計時間。可以清楚看到使用\_\_device\_\_ 與 cuda 內建 min 函數在 GPU 上執行是最快的,而以#define 寫一個比較大小的 macro 還有 if 則慢很多,差異接近兩倍。

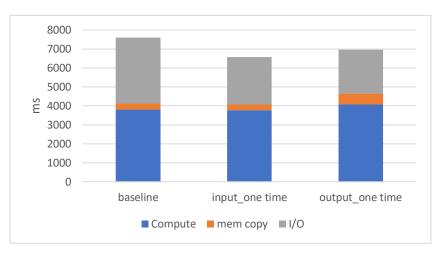
### 4. IO 優化

另外進行了 IO 相關優化實驗,同樣使用 p16k1 測資,測量方式是使用 cudaEvent 計算每部分累計時間。

Baseline 是使用原來助教範例程式中的 input 與 output 程式 Input\_one time 是使用

int \*fpt = (int\*)mmap(NULL, 2\*sizeof(int), PROT\_READ, MAP\_PRIVATE, file, 0);直接將所有資料一次性讀取,之後再寫入 V\*V 的 Dist 中,

而 output\_one time 則是在先三個 phase 結束後先在 gpu 上用 devicetodevice 的 CudaMemcpy 把本來 V\*V 存在 dst 的資料複製到另一個 vertex\*vertex 大小的 dst\_, 之後 output 時就可以直接 fwrite(Dist, sizeof(int), vertex\*vertex, outfile);一次性把 vertex\*vertex 量的資料全部寫入 output file 中減少 I/O 時間。

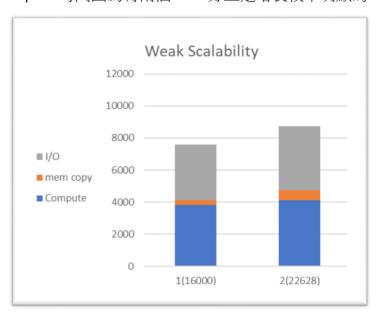


結果可看出 IO 時間都有降低,尤其 input\_one time 十分顯著,output\_one time 雖然也講了不少 IO 時間,但因為要做更多的 CudaMemcpy 所以 memory copy 時間也有增長。

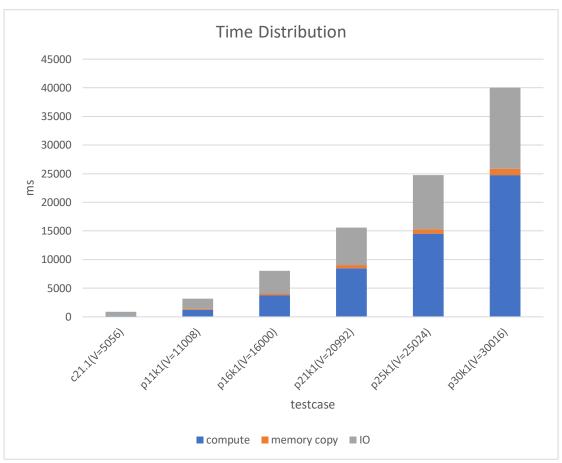
## d. Weak scalability (hw3-3)

Weak scalability 是在每個計算單元計算量相同時比較不同數量計算單元能否在 差不多時間內完成任務,在此使用數量為 1 與 2 的 GPU 進行測試,直接修改程 式內 V 的值測試計算時間。測量方式是使用 cudaEvent 計算每部分累計時間。 兩個 GPU 計算量應為一個的兩倍(V\*V 兩倍),故 V 應為 $\sqrt{2}$ 倍,這裡單 GPU 使用 16000 與其 $\sqrt{2}$ 倍也就是雙 GPU V 為約 22628 比較,單位為 ms。

可看出雙 GPU 仍高出單 GPU 一些時間,執行時間約為單 GPU 1.2~1.3 倍,可發現有較明顯增長的是 I/O 以及 memory copy,I/O 方面已經有使用一次性 mmap 毒入來節省時間,但後續將內容寫入 Dist 應仍會造成時間差異,此外雙 GPU 運行時每個迴圈要進行兩個 GPU 間 CudaMemcpy,這也造成 memory copy 時間明顯增長,而 compute 時間因為有兩個 GPU 分工是增長較不明顯的。



## e. Time Distribution (hw3-2)



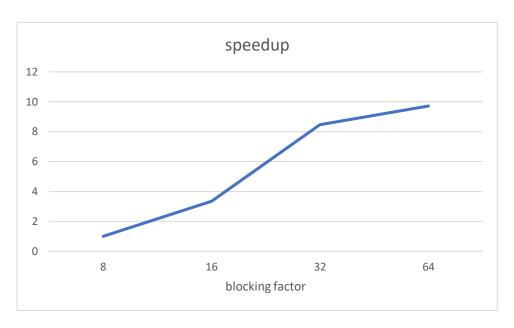
測試六個V值不同的testcase,測量方式是使用cudaEvent計算每部分累計時間。可看出Memory copy時間是佔比最少的,其上漲幅度也很低,主因是memory copy時間主要在執行cudaMemcpy時,此函數主要是在copy V\*V的資料量,因此只和input問題的節點數量有關。

接著是I/O時間,I/O時間,同樣來自於input問題大小,由於input, output兩個函數要不斷進行fread,fwrite,其成長幅度高於memory copy。

最後是compute time, compute time不只和input節點數量有關,也和input距離 矩陣內容有關,其內容會影響計算量,其時間上升幅度也是三者中最大的。

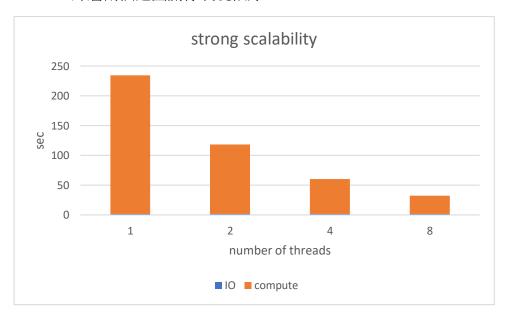
### f. Others

1. 在 large blocking factor 部分可看出 large blocking factor 的確有益於執行時間,這裡進一步觀察 speedup 程度



其實我本來以為 blocking factor 的 speedup 理想應該會和 block 大小成比,也就是 16\*16 會是 8\*8 四倍...以此類推,但實驗做出來明顯不是這樣,但整體 speedup 其實仍算有維持差不多的斜率。

2. 對 hw3-1 部分有花點時間驗證其 strong scalability,使用 c20.1 測 edge:7594839 vertex:5000,可以看到 strong scalability 因為有 omp 平行化 Floyd Warshal 外層兩個迴圈關係表現很好。



## **Experience & Conclusion**

本作業花很多時間在後面兩個 cuda 的部分上面, 在第一部分,其實很多測資都是屬於 edge 稀疏的矩陣,理論上 Floyd-Warshal 時間複雜度 O(n³),並不適合 edge 稀疏的矩陣,可能用 Johnson 更適合,但 Johnson 的實作複雜且不易加入平行化,我最終還是先選擇 Floyd-Warshal+平行 化通過 judge,想說之後再回來實驗 Johnson,結果後來就花了大量時間在後面 兩個關於 cuda 的部分上,沒時間回來弄 Johnson 了。

不過在 cuda 上面我覺得學習 cuda 程式帶給我一種寫程式時的「空間感」,好像以前寫的程式都是線性的,以前平行化想的都只是如何把 for 迴圈拆分。如今突然變成二維甚至三維的感覺,進入另一個新世界,還學到 share memory、注意 bank conflict 概念等等,一口氣前進好多步。